RAPPORT DE PROJET — UE CONDUITE DE PROJET 2025–2026

Indices de prix immobiliers hédoniques Hauts-de-France

Construction d'indices de prix à qualité constante au niveau commune × mois pour la région Hauts-de-France, 2010–2025, en distinguant appartements et maisons.

Région Hauts-de-France — 2010 à 2025

UE Conduite de Projet

Année universitaire 2025–2026

DIB Adel · BAH Alpha Oumar

Master 1 APE / SE — Université de Strasbourg

SOMMAIRE

1. Contexte et objectif
2. Données
3. Méthodologie
4. Pipeline de construction de l'indice

5. Résultats
6. Visualisations et interprétations
7. Difficultés techniques
8. Conclusion

01 — Contexte

Objectif du projet

Le prix moyen observé sur un marché immobilier varie lorsque la composition des biens vendus change — plus de neuf, de grandes surfaces, de biens mieux situés — sans que le marché lui-même n'ait évolué. Suivre naïvement le prix moyen dans le temps produit donc un indicateur biaisé, mêlant effets de composition et évolution réelle des valeurs de marché.

Ce projet construit des **indices de prix à qualité constante** au niveau **commune × mois** pour la région Hauts-de-France sur la période 2010–2025, séparément pour les appartements et pour les maisons. La méthode hédonique permet de répondre à cette question en contrôlant les caractéristiques observables des biens pour ne mesurer que l'évolution du marché net de tout effet de composition.

> **Question centrale :** si le prix moyen augmente, est-ce parce que le marché a vraiment progressé, ou parce qu'on vend des biens plus grands, plus neufs, mieux localisés cette année que l'an dernier ?

La région Hauts-de-France couvre cinq départements : l'Aisne (02), le Nord (59), l'Oise (60), le Pas-de-Calais (62) et la Somme (80), représentant une grande diversité de marchés locaux — métropole lilloise, bassin minier, zones rurales, littoral.

02 — Données

Sources et préparation des données

Sources mobilisées

Source	Période	Observations brutes	Format
DVF+ — data.gouv.fr	2014 – 2025	1 181 643	CSV (pipe)
DV3F — fourni par l'enseignant	2010 – 2013	236 646	Parquet
Total après nettoyage		**1 074 908**	—

Harmonisation des deux bases

Les deux bases n'ont pas une structure identique. La variable VEFA (Vente en l'État Futur d'Achèvement) peut valoir `"t"`, `"TRUE"` ou `1` selon la source. Deux fonctions utilitaires ont été construites :

- **extraire()** — sélectionne les colonnes utiles et crée des colonnes vides pour les absentes, afin d'obtenir des tables de structure identique avant empilement.
- **harmoniser()** — normalise les types : codes département en deux chiffres, variables numériques converties, VEFA en booléen uniforme.

Les deux bases sont ensuite empilées via `rbindlist` sans chevauchement temporel : DV3F couvre exclusivement 2010–2013, DVF+ à partir de 2014.

Nettoyage et filtres appliqués

01 **Type de mutation**

Seules les ventes sont conservées. Les échanges, donations et apports en société ne reflètent pas un prix de marché librement négocié.

02 **Filtre prix au m²**

Exclusion des biens hors de la plage [200 €/m² – 20 000 €/m²]. En-dessous : erreurs de saisie ou biens très dégradés. Au-dessus : hors marché régional.

03 **Variables nbatp**

Filtre sur les variables `nbatp1pp` à `nbatp5pp` : seules les valeurs 0 ou 1 sont conservées pour garantir qu'il s'agit d'un bien unique homogène.

04 **Séparation appartements / maisons**

Utilisation des variables numériques `nblocapt` et `nblocmai`, encodées de façon homogène dans les deux bases, plutôt que du libellé textuel `libtypbien` (encodage hétérogène).

05 **Log-transformation du prix**

Le prix au m² est passé en logarithme, transformation standard en économétrie : elle stabilise la variance et permet d'interpréter les coefficients comme des effets multiplicatifs.

03 — Méthodologie

Le modèle hédonique log-linéaire

Le modèle hédonique repose sur l'idée que le prix d'un bien peut être décomposé en la somme des valeurs implicites de ses attributs. En log-linéaire, on estime :

Équation du modèle hédonique

$$\log(p_i) = \alpha + \mathbf{x_i'\beta} + \boldsymbol{\gamma_{t(i)}} + \delta_{d(i)} + \mu_{c(i)} + \theta_{d(i),a(i)} + \varepsilon_i$$

Terme	Rôle dans le modèle
$x_i'\beta$	Variables de qualité : log(surface bâtie), VEFA, typologies T1/T3/T4/T5 pour les appartements, log(surface terrain) et typologies P pour les maisons
γ_t	**Effet fixe temps (mois × année)** — tendance de marché commune à qualité constante. C'est ce terme qui sert à construire l'indice.
δ_d	Effet fixe département — niveau de prix structurel par département
μ_c	Effet fixe commune — niveau de prix structurel local, non estimé librement pour les 100 communes les moins liquides
$\theta_{d,a}$	Interaction département × année — tendances spécifiques à chaque département sur chaque année

Choix des variables de qualité

log(surface bâtie)

Le log est préféré au niveau pour capturer la relation non linéaire entre surface et prix au m² : les petites surfaces se vendent structurellement plus cher (rendements décroissants). Utiliser le niveau biaiserait l'indice en faveur des périodes à forte vente de grands logements.

VEFA — Vente en l'État Futur d'Achèvement

Le neuf se vend avec une prime systématique sur l'ancien. Sans ce contrôle, un pic de construction neuve dans une commune ferait artificiellement monter son indice, sans que le marché existant n'ait évolué.

Typologies (T1–T5 / P1–P5)

Les F1 et F5 ont des prix au m² structurellement différents des F2–F3. Cette correction est cruciale car le mix de typologies varie selon les cycles économiques. T2 est choisi comme référence (54 002 observations) car c'est la catégorie la plus fréquente, ce qui stabilise l'estimation.

log(surface terrain) — maisons uniquement

Le terrain est une composante de valeur propre aux maisons. Ne pas l'inclure ferait confondre valeur foncière et tendance de marché dans les communes périurbaines.

> **Note :** l'objectif du modèle est la prédiction, non l'inférence causale. La multicolinéarité entre dummies n'est pas un problème dans ce cadre. Les variables manquantes dans DVF (état du bien, étage, exposition) constituent une limite connue et subie.

Implémentation

Les deux modèles (appartements / maisons) sont estimés séparément avec la fonction `feols()` du package R **fixest**, qui permet d'absorber des milliers d'effets fixes de façon algorithmiquement efficace, sans créer de colonnes indicatrices explicites en mémoire.

04 — Pipeline

Du modèle à l'indice : 9 étapes

Toute la chaîne est encapsulée dans une fonction `pipeline_hedonique()` qui prend en entrée la table d'un segment (appartements ou maisons) et produit l'indice base 100.

01

Choix des références

Période de référence temporelle = plus ancienne période disponible dans les données (choix important pour éviter que les données de 2010 soient éliminées par les garde-fous). Département de référence = Nord (59), le plus grand volume de ventes.

02

Identification des petites communes

Les 100 communes avec le moins de transactions ne reçoivent pas d'effet fixe communal

estimé librement — trop peu d'observations créerait du sur-ajustement. Elles sont regroupées sous un niveau commun contraint à zéro.

03

Construction des effets fixes

Création des variables facteurs avec niveaux de référence correctement assignés. L'opération `relevel()` est effectuée hors du contexte `data.table` pour éviter un bug silencieux d'évaluation tardive.

04

Estimation OLS via feols()

Estimation du modèle log-linéaire avec effets fixes multiples sur l'ensemble des observations du segment.

05

Calcul du log prix net

Pour chaque transaction : valeur prédite (temps + lieu + qualité) moins la contribution estimée des seules variables de qualité (surface, VEFA, typologies). Ce qui reste est un prix "nettoyé" ne reflétant que localisation et tendance temporelle.

06

Correction des petites communes

Pour les communes sans effet fixe propre, recalage a posteriori par ajout du résidu moyen communal — écart systématique entre prix réel et prix prédit.

07

Agrégation commune × mois

Médiane (robuste aux valeurs aberrantes résiduelles) du log prix net pour chaque cellule. Seuil minimum : 3 transactions pour qu'une cellule soit considérée "observée".

08

Complétion des périodes manquantes

Prédiction des mois sans transaction en appliquant les effets fixes estimés (constante + effet temps + commune + département + interaction). Prédicton uniquement si tous les effets fixes sont disponibles. Garde-fou ±3 écarts-types. Valeurs taguées pour distinction dans les graphiques.

09

Indice base 100

$\text{Index}_{c,t} = 100 \times \exp(\log P^{net}_{c,t} - \log P^{net}_{c,t_0})$. Un indice de 120 en 2022 signifie +20 % à qualité constante par rapport à la base. Garde-fou final : |diff_log| ≤ log(5).

05 — Résultats

Résultats des modèles estimés

Statistiques d'ajustement globales

Appartements

0.616

R^2 global

Observations	38 282
Communes	430
R^2 ajusté	0.505
R^2 within	0.154
RMSE	0.302

Maisons

0.507

R^2 global

Observations	806 942
Communes	4 192
R^2 ajusté	0.425
R^2 within	0.154
RMSE	0.395

Le R^2 within de 0.154 pour les deux segments est instructif : une fois les effets géographiques et temporels retirés, les variables de qualité pures (surface, terrain, typologie) expliquent seules environ 15 % de la variabilité résiduelle des prix. Le R^2 global plus faible pour les maisons (0.507 vs 0.616) s'explique par l'hétérogénéité plus importante de ce segment — état du bien, configuration, terrain — non captée par les variables disponibles dans DVF.

Coefficients estimés — Appartements

Variable	Coefficient	Std. Error	Signif.	Interprétation
log_sbati	−0.300	0.006	***	+10 % surface → −3 % du prix/m² (rendements décroissants)
vefa_num	+0.357	0.040	***	Prime neuf ≈ +42,9 % vs bien ancien comparable
T1 (vs T2)	−0.040	0.006	***	Studios : −4 % par rapport au T2 de référence
T3 (vs T2)	+0.014	0.005	**	Légère prime T3 sur T2
T4 (vs T2)	−0.023	0.006	***	T4 légèrement décoté
T5 (vs T2)	+0.049	0.009	***	Grands appartements : +5 % environ

Coefficients estimés — Maisons

Variable	Coefficient	Std. Error	Signif.	Interprétation
log_sbati	−0.430	0.001	***	+10 % surface → −4,3 % du prix/m² (effet plus fort que pour les appts)
log_sterr	+0.170	0.001	***	+10 % terrain → +1,7 % du prix/m² à surface constante
vefa_num	+0.211	0.091	*	Prime neuf maisons ≈ +23,5 % (inférieure à celle des appartements)
P1 (vs P3)	−0.198	—	***	Très petites maisons : −18 % par rapport au P3
P5 (vs P3)	+0.104	—	***	Grandes maisons : +11 % environ

> La prime VEFA est nettement plus élevée pour les appartements (+42,9 %) que pour les maisons (+23,5 %). Cela s'explique par la concentration du neuf en appartements dans les zones urbaines denses, où la tension immobilière amplifie le premium neuf.

Indice final — Statistiques descriptives

Appartements — Indice final	
Minimum	86.3
Médiane	94.6
Moyenne	94.6
Maximum	100.1

Maisons — Indice final	
Minimum	78.4
Médiane	88.9
Moyenne	90.8
Maximum	109.1

06 — Visualisations & interprétations

Analyse des résultats

Dynamique régionale : trois phases distinctes

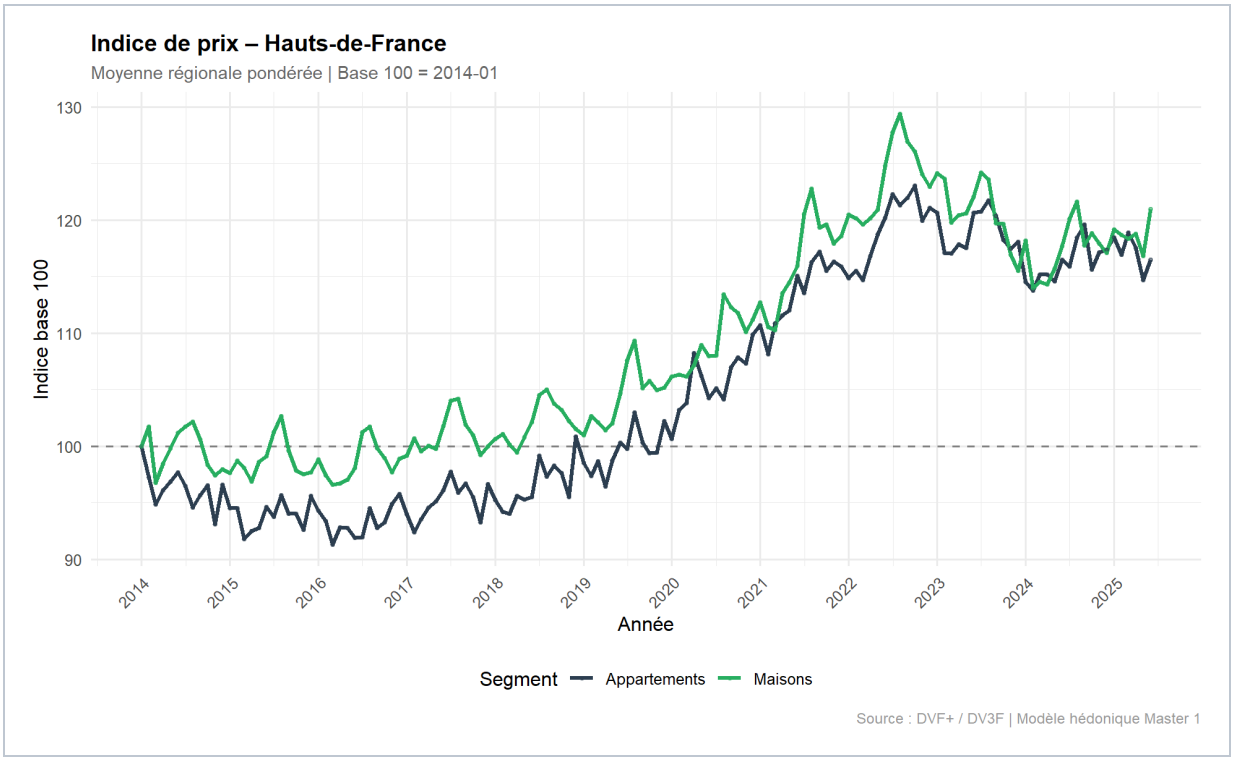

Figure 1 — Évolution de l'indice hédonique régional moyen (base 100 = janvier 2014)

2010 – 2018

Stagnation post-crise et repli des appartements

Le marché régional est atone. L'indice des maisons oscille sans tendance. Les appartements subissent une décote marquée, descendant jusqu'à un indice d'environ 92 en 2015–2016, soit −8 % par rapport à la base 2014. Le marché reflète les séquelles de la crise de 2008 et la stagnation des revenus.

2019 – 2022

Hausse accélérée et "effet Covid"

À partir de 2019, les deux courbes amorcent une reprise qui s'accélère brutalement en 2020–2021. Les maisons surperforment nettement : leur indice culmine à environ 130 mi-2022 (+30 % à qualité constante depuis 2014). Les appartements atteignent un pic plus modéré (~122). Le décrochage entre les deux segments traduit la ruée vers les maisons avec extérieur consécutive aux confinements et aux taux historiquement bas.

2023 – 2025

Correction et convergence

La remontée brutale des taux BCE provoque un retournement sévère. Les prix des maisons chutent fortement et rejoignent la courbe des appartements. En 2024–2025, les deux marchés se stabilisent et évoluent de concert entre 115 et 120. La région conserve néanmoins une plus-value structurelle de l'ordre de +15 % à +20 % sur dix ans, à qualité constante.

Disparités communales — Appartements

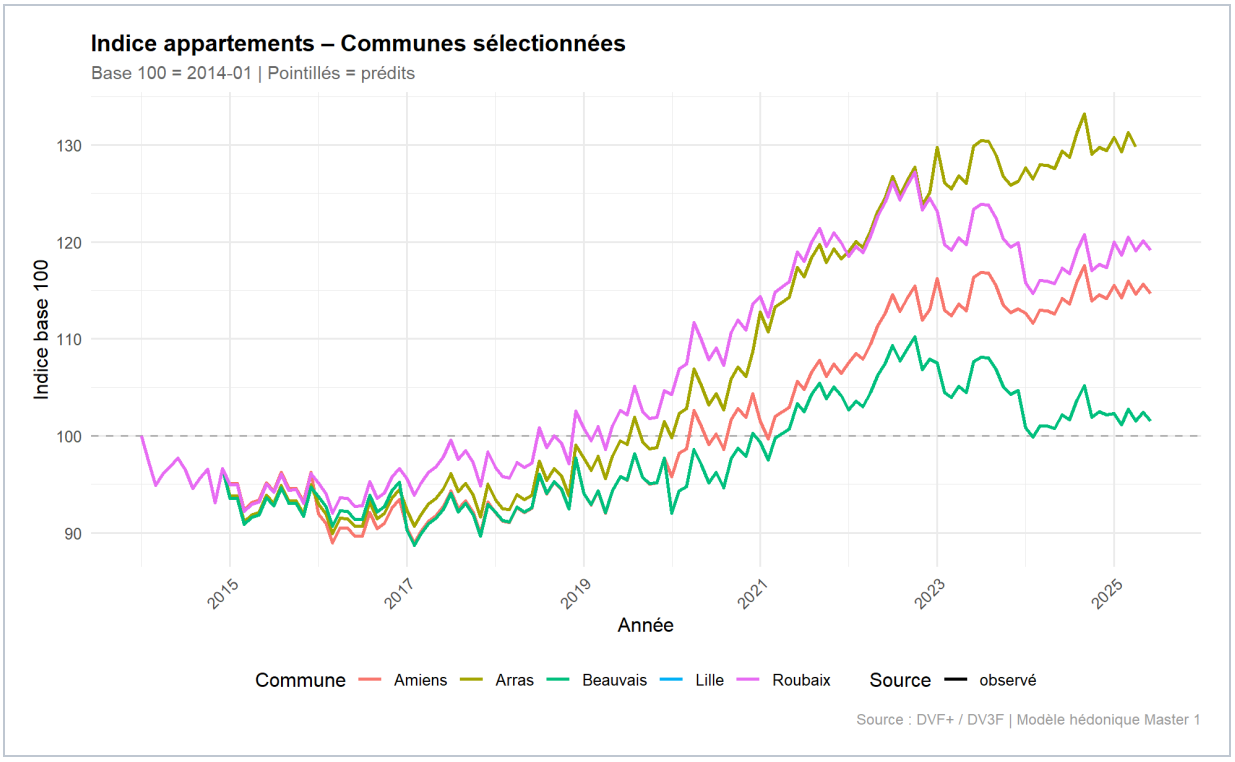

Figure 2 — Indice hédonique des appartements pour les communes sélectionnées

Les courbes communales illustrent l'intérêt de la modélisation hédonique à l'échelle locale : derrière une moyenne régionale en hausse se cachent des trajectoires radicalement différentes.

Commune	Profil	Indice 2025 (approx.)
Arras	Marché le plus dynamique. Forte accélération à partir de 2018, très peu affectée par la correction post-2022.	≥ 130
Roubaix	Forte flambée jusqu'à mi-2022 (effet de rattrapage et attrait des investisseurs), suivie de la correction la plus abrupte.	~120
Amiens	Croissance régulière et "sage", pic 2022 peu prononcé.	~115
Beauvais	Marché le moins porteur. Bulle post-Covid très faible, correction ayant effacé les gains. Retour au niveau 2014.	~100

Focus Lille — Appartements vs Maisons

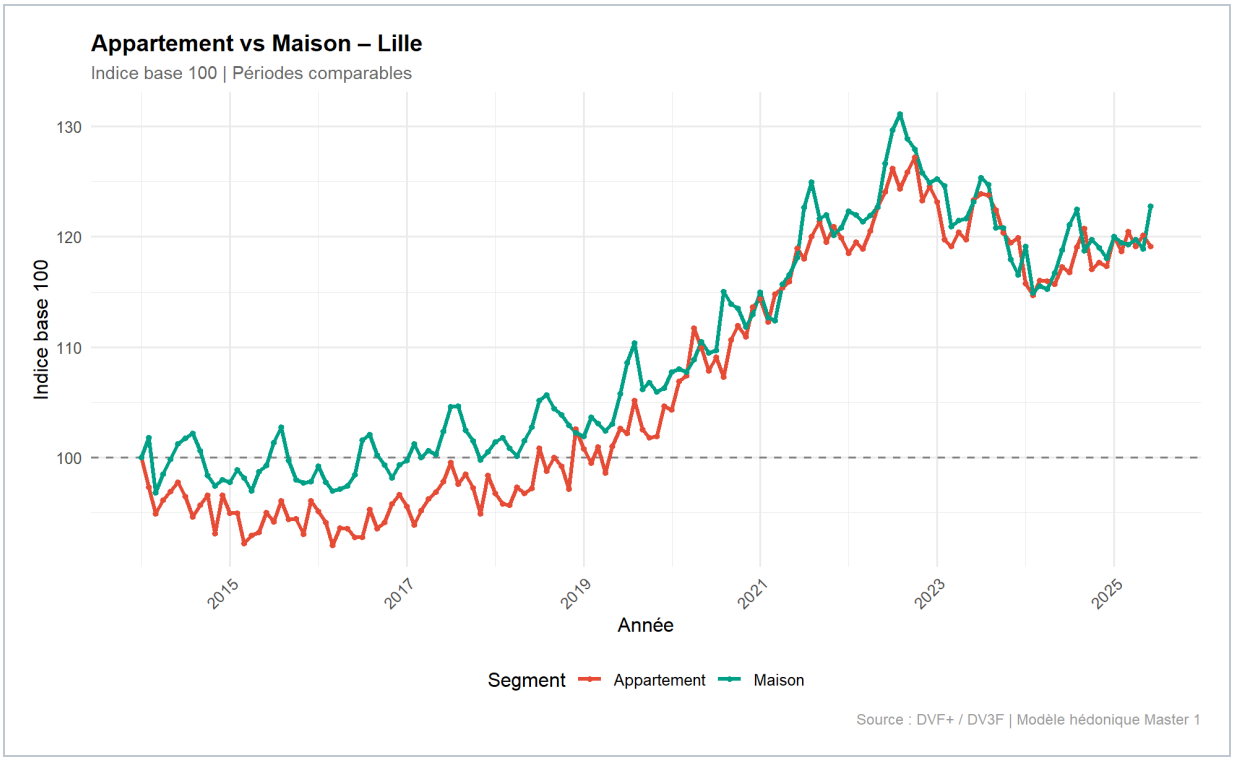

Figure 3 — Comparaison des indices hédoniques appartements / maisons à Lille

À Lille, les deux segments convergent sur la longue période malgré des dynamiques différentes à court terme. En début de période, les maisons bénéficient d'une prime claire (indice stable ~100 vs appartements ~95). Le rattrapage des appartements s'opère en 2021. Lors du pic de l'été 2022, les maisons reprennent temporairement le dessus (~130 vs ~127 pour les appartements). Depuis 2023, les deux courbes se superposent presque parfaitement autour d'un indice de 120, signe que les chocs macroéconomiques harmonisent les dynamiques à long terme, quelle que soit la nature du bien.

Carte choroplèthe — Indice moyen par commune (Appartements)

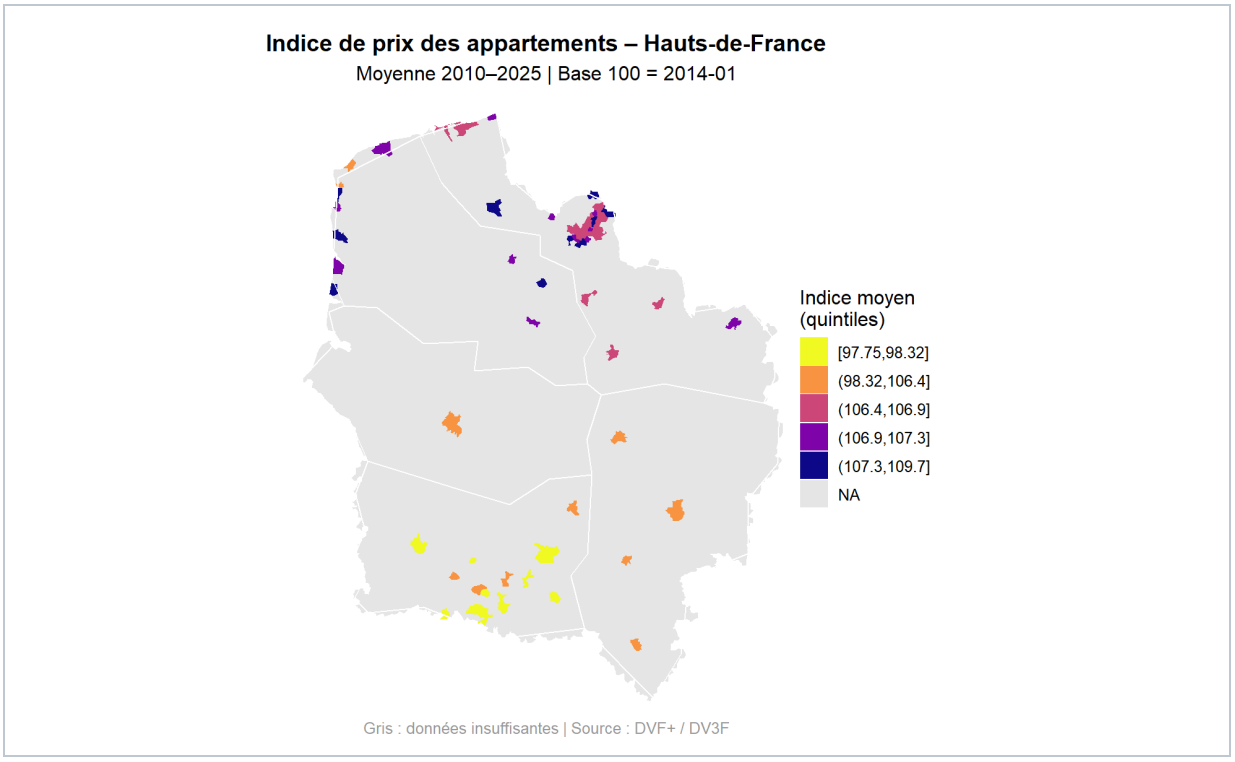

Figure 4 — Carte choroplèthe de l'indice moyen des appartements par commune (2010–2025)

Géographie des prix — Effets fixes communaux

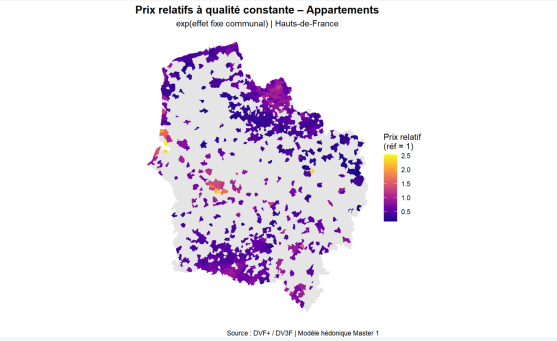

Figure 5 — Effets fixes communaux estimés — Appartements (exp(μ_c))

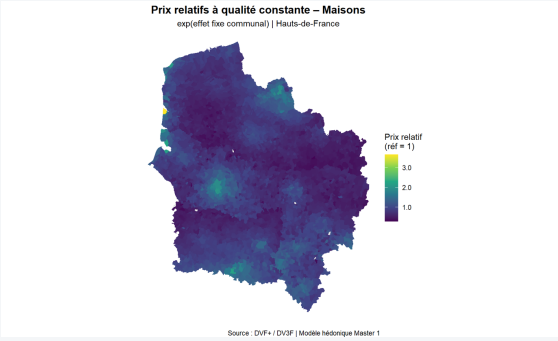

Figure 6 — Effets fixes communaux estimés — Maisons (exp(μ_c))

Les cartes des effets fixes $\exp(\mu_c)$ fournissent une mesure structurelle de l'attractivité résidentielle, purgée de l'effet temps et des caractéristiques physiques des biens.

Points chauds identifiés

Façade littorale (Côte d'Opale) — Le Touquet affiche des prix relatifs dépassant 2,5 pour les appartements et jusqu'à 3,0 pour les maisons. Marché tiré par les résidences secondaires.

Métropole lilloise — Large auréole de prix élevés, particulièrement visible pour les maisons (fort attrait du périurbain lillois).

Extrême sud (Oise) — Proximité et attractivité du bassin parisien tirent les prix à la hausse dans plusieurs communes.

A contrario, la grande majorité du territoire régional — ancien bassin minier, zones rurales de l'Aisne et de la Somme — affiche des prix relatifs inférieurs ou égaux au niveau de référence, confirmant le caractère structurellement accessible de l'immobilier dans ces marchés.

Heatmaps — Top 30 communes

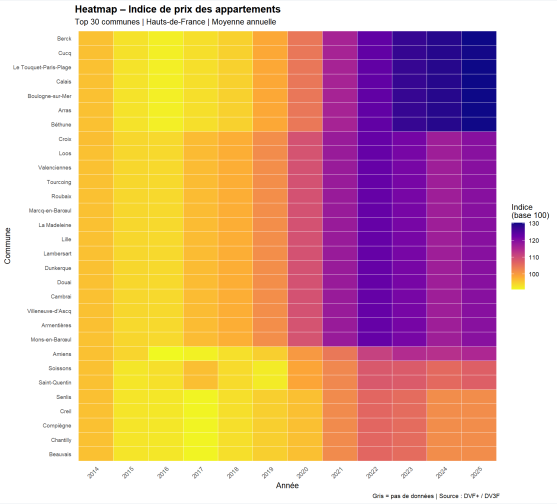

Figure 7 — Heatmap commune × année (appartements) — 30 communes les plus actives

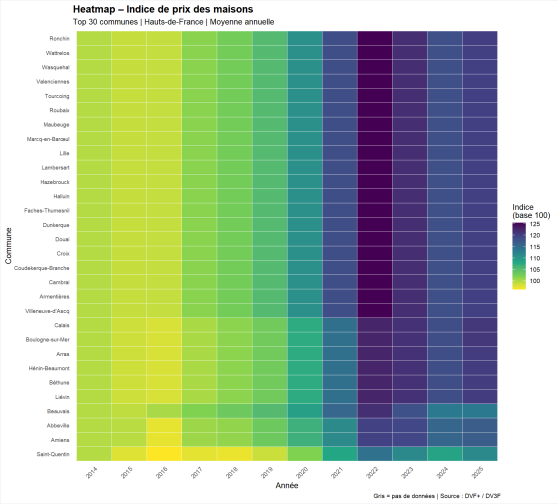

Figure 8 — Heatmap commune × année (maisons) — 30 communes les plus actives

Les heatmaps croisent les 30 communes les plus actives avec les années et confirment les dynamiques observées, avec une granularité supplémentaire :

Pour les **appartements**, le haut du classement (indice > 130) est dominé par les communes côtières — Berck, Cucq, Le Touquet, Calais, Boulogne-sur-Mer. Le bas du tableau regroupe les pôles urbains de l'Oise et de l'Aisne (Beauvais, Chantilly, Compiègne, Soissons).

Pour les **maisons**, la géographie de la hausse est radicalement différente : le haut du classement est entièrement dominé par la couronne métropolitaine lilloise — Ronchin, Wattrelos, Wasquehal, Tourcoing, Roubaix, Marcq-en-Barœul. L'exode urbain post-Covid vers les maisons avec jardin a frappé de plein fouet l'agglomération nordiste.

07 — Difficultés techniques

Difficultés rencontrées et solutions

Encodage hétérogène des types de biens

L'utilisation initiale du libellé textuel `libtypbien` pour distinguer appartements et maisons a conduit à la disparition de toutes les données 2010–2013, encodées différemment dans DV3F. **Solution :** utilisation des compteurs numériques `nblocapt` et `nblocmai`, homogènes entre les deux sources.

Modification en place par data.table

`data.table` modifie les objets directement en mémoire sans copie. Au second appel du pipeline (pour les maisons), des colonnes parasites créées lors du premier appel (appartements) corrompaient silencieusement le modèle. **Solution :** ajout d'un `dt <- copy(dt)` en première ligne du pipeline.

Bug silencieux de relevel() dans data.table

L'utilisation de `relevel()` à l'intérieur de la syntaxe `dt[...]` causait une évaluation prématurée du facteur avant que le niveau de référence "REF_PETITES" ne soit présent dans les données — sans message d'erreur. **Solution :** exécution de `relevel()` hors du contexte data.table via la syntaxe `dt$colonne <- relevel(...)`.

Troncature de la heatmap avant 2013

La période de référence initialement choisie (mois avec le plus de transactions, ~2019–2021) éloignait trop les observations de 2010–2013, qui étaient alors éliminées par le garde-fou sur les variations de l'indice. **Solution :** choix de la plus ancienne période disponible comme référence, et élargissement du garde-fou.

08 — Conclusion

Synthèse

Ce projet a produit des indices de prix immobiliers hédoniques par commune et par mois pour les Hauts-de-France sur quinze ans, séparément pour les appartements et pour les maisons. Le modèle OLS à effets fixes multiples, estimé sur plus d'un million de transactions, permet une mesure d'évolution des prix à qualité constante bien plus rigoureuse qu'un suivi de prix moyen brut.

Les résultats documentent trois phases économiques nettes : une stagnation post-crise jusqu'en 2018, une forte accélération portée par les taux bas et l'effet Covid jusqu'en 2022, puis un retournement brutal lié à la remontée des taux BCE. La région conserve malgré la

correction récente une plus-value structurelle de +15 % à +20 % à qualité constante sur dix ans.

Sur le plan spatial, les analyses confirment la polarisation du marché immobilier des Hauts-de-France : d'un côté, des pôles métropolitains (Lille) et littoraux (Côte d'Opale) très dynamiques ; de l'autre, d'immenses zones rurales et urbaines secondaires à l'immobilier structurellement accessible. L'originalité du segment appartements réside dans la surperformance du littoral ; celle du segment maisons, dans la domination de la couronne lilloise.

> **Limites identifiées :** variables de qualité manquantes dans DVF (état du bien, étage, exposition, surface terrain pour les appartements) ; spécification maisons restreinte (R^2 within = 0.023) ; hypothèse de stabilité temporelle des effets fixes pour la complétion des trous.

Ces indices constituent une base solide pour des analyses économiques plus poussées — études d'accessibilité résidentielle, détection de bulles locales, évaluation de l'impact de politiques urbaines — sur la région Hauts-de-France.

DIB Adel · BAH Alpha Oumar — Master 1 APE/SE, Université de Strasbourg — UE Conduite de Projet 2025–2026

Sources : DVF+ (data.gouv.fr) · DV3F (Moodle) · Modèle hédonique estimé sous R (fixest, data.table)